

LAB1_AI

Partie 1 — Préparation de l'environnement

Q1. Quelle est la commande permettant d'installer une bibliothèque avec pip

`pip install nom_de_la_bibliothèque`

Exemple: `pip install nltk`. In a notebook, prefix with `!`: `!pip install nltk`.

Q2. Quelle est la différence entre nltk et spaCy selon vous ?

Critère	NLTK	spaCy
Objectif	Pédagogique / recherche	Production / industrie
Vitesse	Plus lent	Très rapide (écrit en Cython)
API	Modulaire (beaucoup de choix)	Opinionated (un seul pipeline)
Fonctions	Tokenisation, stemming, POS, corpus variés	Tokenisation, POS, NER, dépendances, vecteurs
Modèles	Règles + corpus	Modèles statistiques/neuronaux pré-entraînés

En résumé : **NLTK** est idéal pour apprendre et expérimenter ; **spaCy** est optimisé pour les applications réelles à grande échelle.

Partie 2 — Nettoyage du texte

Q1. Pourquoi est-il important de mettre le texte en minuscules ?

Pour garantir la **cohérence** : « Hello », « hello » et « HELLO » doivent être traités comme le même mot. Sans cela, le vocabulaire explose et les fréquences sont faussées (ex. « Apple » et « apple » compteraient comme deux tokens distincts).

Q2. Exemple avant / après nettoyage

- **Avant** : "Hello, World!!! NLP is AMAZING..."
- **Après** : "hello world nlp is amazing"

La ponctuation et les majuscules ont été supprimées, ne laissant que les mots utiles.

Partie 3 — Tokenisation et Stopwords

Q1. Que représentent les stopwords ?

Ce sont des mots **très fréquents** mais **pauvres en information sémantique** (articles, prépositions, pronoms, auxiliaires : *the, is, a, of, it...*). On les retire pour se concentrer sur les mots porteurs de sens.

Q2. Quelle proportion du texte original est supprimée après leur retrait ?

Dans notre exemple : 3 mots supprimés sur 11 → environ **27 %**. En général, les stopwords représentent **40–50 %** d'un texte en anglais.

Partie 4 — Lemmatisation

Q1. Différence entre stemming et lemmatisation ?

Critère	Stemming	Lemmatisation
Principe	Coupe des affixes (règles brutes)	Utilise un dictionnaire + POS
Résultat	Racine parfois non réelle (<i>studi</i>)	Forme réelle du dictionnaire (<i>study</i>)
Exemple	<i>studies</i> → <i>studi</i>	<i>studies</i> → <i>study</i>
Vitesse	Rapide	Plus lent
Précision	Faible	Élevée

Q2. Pourquoi cette étape est-elle importante avant l'analyse sémantique ?

Elle **regroupe les variantes d'un même mot** (*run, runs, running, ran* → *run*), ce qui :

- Réduit la dimensionnalité du vocabulaire.
- Améliore la **généralisation** des modèles (TF-IDF, classification, clustering).
- Évite de traiter comme différents des mots portant le même sens.